

07 - Modélisation - Régression

PRO1036 - Analyse de données scientifiques en R

Tim Bollé

November 10, 2025

L'analyse de données - Kesako?

Les cinq activités principales

1. Formuler et préciser la question
2. Explorer les données
3. Construire des modèles statistiques
4. Interpréter les résultats
5. Communiquer les résultats

Formuler et préciser la question

Types de questions/problèmes

- **Description**: résumer des caractéristiques d'un jeu de données.
- **Exploration**: découvrir des relations, des patterns entre variables (formuler des hypothèses).
- **Inférence**: analyser des relations, des patterns entre variables pour en tirer des conclusions générales, en utilisant des données représentatives (échantillon) d'une population générale (tester des hypothèses)
- **Prédiction**: prédire la valeur d'une variable future/inconnue à partir de données passées/connues (*machine learning*)
- **Causalité**: comprendre l'effet d'une variable sur une autre variable (relation de cause à effet).
- **Mécanismes**: comprendre les processus sous-jacents qui génèrent les données observées.


Explorer les données

Construire des modèles statistiques


Modélisation

Les modèles sont utilisés pour expliquer des relations entre variables et pour faire des prédictions.

Linéaire



Non linéaire



Les données du jour : Paris painting

Données issues des catalogues de 28 ventes aux enchères de tableaux de Paris entre 1764 et 1780.



Paris painting

```
1 pp <- read_csv("data/paris-paintings.csv", na = c("n/a", "", "NA"))
1 pp %>%
2   glimpse()
```

Rows: 3,393


Columns: 61

```
$ name      <chr> "L1764-2", "L1764-3", "L1764-4", "L1764-5a", "L1764-...
$ sale      <chr> "L1764", "L1764", "L1764", "L1764", "L1764", "L1764"...
$ lot       <chr> "2", "3", "4", "5", "5", "6", "7", "7", "8", "9", "9...
$ position  <dbl> 0.03278689, 0.04918033, 0.06557377, 0.08196721, 0.08...
$ dealer    <chr> "L", "L", "L", "L", "L", "L", "L", "L", "L", "L", "L...
$ year      <dbl> 1764, 1764, 1764, 1764, 1764, 1764, 1764, 1764, 1764...
$ origin_author <chr> "F", "I", "X", "F", "F", "X", "F", "F", "X", "D/FL",...
$ origin_cat  <chr> "O", "O", "O", "O", "O", "O", "O", "O", "O", "O", "O...
$ school_pntg <chr> "F", "I", "D/FL", "F", "F", "I", "F", "F", "I", "D/F...
$ diff_origin <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
$ logprice   <dbl> 5.8861040, 1.7917595, 2.4849067, 1.7917595, 1.791759...
$ price      <dbl> 360.0, 6.0, 12.0, 6.0, 6.0, 9.0, 12.0, 12.0, 24.0, 6...
$ count      <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
$ subject    <chr> "L'enfant Jesus", "Homme portant un panier", "L'enfa...
$ authorstandard <chr> "Grimou, Alexis", "Fetti, Domenico", "copy after Dyc...
$ artistliving <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ authorstyle  <chr> NA, NA, "copy after", NA, NA, "copy after", NA, NA, ...
$ author      <chr> "Grimou", "F\x8ety", "copi\x8e d'apr\x8fs Wandeik", ...
$ winningbidder <chr> "Unknown", "Unknown", "Unknown", "Unknown", "Unknown..."
```


Relation Largeur/Hauteur

Hauteur vs Largeur

```
1 ggplot(data = pp, aes(x = Height_in)) +
2   geom_histogram(binwidth = 5) +
3   labs(x = "Hauteur, en pouces", y = NULL)
```




```
1 ggplot(data = pp, aes(x = Width_in)) +
2   geom_histogram(binwidth = 5) +
3   labs(x = "Largeur, en pouces", y = NULL)
```



Hauteur et largeur

Graphe Code

Hauteur vs. Largeur des peintures
Ventes aux enchères à Paris, 1764 - 1780




... Personnalisé

Graphe Code

Hauteur vs. Largeur des peintures

Ventes aux enchères à Paris, 1764 - 1780



Vocabulaire

Modélisation

- **Variable dépendante (expliquée)**: Variable dont on cherche à comprendre le comportement ou la variation, sur l'axe des y
- **Variables indépendantes (explicatives)**: Autres variables que l'on utilise pour expliquer la variation de la variable dépendante, sur l'axe des x
- **Valeur prédite**: Résultat de la **fonction modèle**
 - La fonction modèle donne la valeur typique (attendue) de la variable dépendante
- **Résidus**: Mesure de la distance entre chaque observation et sa valeur prédite (basée sur un modèle particulier)
 - $\text{Résidu} = \text{Valeur observée} - \text{Valeur prédite}$
 - Indique à quel point chaque observation est au-dessus/en-dessous de la valeur attendue


Variables explicatives multiples

Pensez vous que la hauteur d'une peinture peut être expliquée uniquement par sa largeur ?


[Graphe](#) [Code](#)

Hauteur vs. Largeur des peintures

Ventes aux enchères à Paris, 1764 - 1780



Portraits vs Paysages




Variables explicatives multiples

Est-ce que la relation entre hauteur et largeur dépend de la présence d'éléments paysages ?

Graphes Code


Hauteur vs. Largeur des peintures, selon la présence d'éléments paysages
Ventes aux enchères à Paris, 1764 - 1780




Fitter et interpréter un modèle de régression

Objectif: Prédire la hauteur d'une peinture en fonction de sa largeur

$$\widehat{hauteur}_i = \beta_0 + \beta_1 \times largeur_i$$



Comment ?



Étape 1: Spécifier le modèle

```
1 linear_reg()
```

Linear Regression Model Specification (regression)

Computational engine: lm

Étape 2: Choisir le *engine*

```
1 linear_reg() %>%  
2   set_engine("lm") # lm = linear model - modèle linéaire
```

Linear Regression Model Specification (regression)

Computational engine: lm

Étape 3: Fitter le modèle

Ici il faut indiquer la **formule** et les **données**

```
1 linear_reg() %>%  
2   set_engine("lm") %>%  
3   fit(Height_in ~ Width_in, data = pp)
```

parsnip model object

Call:

```
stats::lm(formula = Height_in ~ Width_in, data = data)
```

Coefficients:

(Intercept)	Width_in
3.6214	0.7808

Résultat du modèle

parsnip model object

Call:

```
stats::lm(formula = Height_in ~ Width_in, data = data)
```

Coefficients:

(Intercept)	Width_in
3.6214	0.7808

$$\widehat{height}_i = 3.62 + 0.781 \times width_i$$

Affichage Tidy

```

1 linear_reg() %>%
2   set_engine("lm") %>%
3   fit(Height_in ~ Width_in, data = pp) %>%
4   tidy()
# A tibble: 2 × 5
  term          estimate std.error statistic  p.value
<chr>         <dbl>     <dbl>     <dbl>    <dbl>
1 (Intercept)    3.62      0.254      14.3 8.82e-45
2 Width_in       0.781     0.00950     82.1 0

```

$$\widehat{height}_i = 3.62 + 0.781 \times width_i$$


Interprétation des coefficients

$$\widehat{height}_i = 3.62 + 0.781 \times width_i$$

- **Ordonnée à l'origine** ($\beta_0 = 3.62$): Hauteur prédite lorsque la largeur est de 0 pouces.
- **Pente** ($\beta_1 = 0.781$): Pour chaque augmentation de 1 pouce de la largeur, la hauteur prédite augmente en moyenne de 0.781 pouces.

Attention aux extrapolations !

Correlation n'est pas causalité !



Valeurs prédites et résidus

We're interested in β_0 (population parameter for the intercept) and β_1 (population parameter for the slope) in the following model: Nous voudrions connaître les paramètres de population β_0 (ordonnée à l'origine) et β_1 (pente) dans le modèle suivant :

$$Y_i = \beta_0 + \beta_1 x_i$$

Mais nous n'avons qu'un échantillon de données...

Nous pouvons estimer ces paramètres à partir de notre échantillon, en utilisant les estimateurs b_0 et b_1 :

$$\hat{y}_i = b_0 + b_1 x_i$$

Estimation des paramètres


Les paramètres sont estimés en minimisant la somme des carrés des résidus :

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Visuellement...

Hauteur vs Largeur des peintures


Juste les données



Visuellement...

Hauteur vs Largeur des peintures


Données + valeurs prédites



Visuellement...

Hauteur vs Largeur des peintures

Données + valeurs prédites + résidus



Valeurs explicatives catégorielles

Variable indépendante catégorielle avec 2 niveaux

```
# A tibble: 3,393 × 3
  name      Height_in landsALL
  <chr>      <dbl>    <dbl>
1 L1764-2      37         0
2 L1764-3      18         0
3 L1764-4      13         1
4 L1764-5a     14         1
5 L1764-5b     14         1
6 L1764-6       7         0
7 L1764-7a     6         0
8 L1764-7b     6         0
9 L1764-8      15         0
10 L1764-9a     9         0
11 L1764-9b     9         0
12 L1764-10a    16         1
13 L1764-10b    16         1
14 L1764-10c    16         1
15 L1764-11     20         0
16 L1764-12a    14         1
17 L1764-12b    14         1
18 L1764-13a    15         1
```

- **landsALL = 0**: Pas d'éléments de paysages
- **landsALL = 1**: Éléments de paysages présents

Hauteur et éléments de paysages

```

1 linear_reg() %>%
2   set_engine("lm") %>%
3   fit(Height_in ~ factor(landsALL), data = pp) %>%
4   tidy()
# A tibble: 2 × 5
  term                estimate std.error statistic  p.value
<chr>                <dbl>    <dbl>    <dbl>    <dbl>
1 (Intercept)         22.7      0.328     69.1  0
2 factor(landsALL) 1   -5.65    0.532    -10.6 7.97e-26

```

$$\widehat{Height}_{in} = 22.7 - 5.645 \text{ landsALL}$$

- **Ordonnée à l'origine** ($\beta_0 = 22.7$): Hauteur prédite pour les peintures sans éléments de paysages (**landsALL = 0**).
- **Coefficient** ($\beta_1 = -5.645$): Différence moyenne de hauteur entre les peintures avec éléments de paysages et celles sans. Les peintures avec éléments de paysages sont en moyenne 5.645 pouces plus courtes que celles sans.

Hauteur et école de peinture

```

1 linear_reg() %>%
2   set_engine("lm") %>%
3   fit(Height_in ~ school_pntg, data = pp) %>%
4   tidy()
# A tibble: 7 × 5
  term                estimate std.error statistic p.value
<chr>                <dbl>    <dbl>    <dbl>    <dbl>
1 (Intercept)         14.0      10.0      1.40    0.162
2 school_pntgD/FL      2.33     10.0      0.232   0.816
3 school_pntgF         10.2     10.0      1.02    0.309
4 school_pntgG          1.65     11.9      0.139   0.889
5 school_pntgI         10.3     10.0      1.02    0.306
6 school_pntgS         30.4     11.4      2.68    0.00744
7 school_pntgX          2.87     10.3      0.279   0.780

```

Dummy variable

```
# A tibble: 7 × 5
  term                estimate std.error statistic p.value
  <chr>                <dbl>    <dbl>    <dbl>    <dbl>
1 (Intercept)         14.0      10.0      1.40    0.162
2 school_pntgD/FL      2.33     10.0      0.232   0.816
3 school_pntgF         10.2     10.0      1.02    0.309
4 school_pntgG          1.65     11.9      0.139   0.889
5 school_pntgI         10.3     10.0      1.02    0.306
6 school_pntgS         30.4     11.4      2.68    0.00744
7 school_pntgX          2.87     10.3      0.279   0.780
```

- Quand une variable catégorielle a plus de deux niveaux, on crée des variables indicatrices (**dummy variables**) pour chaque niveau, sauf un (le niveau de référence).
- Chaque coefficient représente la différence moyenne entre ce niveau et le niveau de référence.

Dummy variable

school_pntg	D_FL	F	G	I	S	X	# A tibble: 3,393 × 3		
							name	Height_in	
							school_pntg		
							<chr>	<dbl>	<chr>
A	0	0	0	0	0	0	1 L1764-2	37	F
D/FL	1	0	0	0	0	0	2 L1764-3	18	I
							3 L1764-4	13	D/FL
F	0	1	0	0	0	0	4 L1764-5a	14	F
							5 L1764-5b	14	F
G	0	0	1	0	0	0	6 L1764-6	7	I
							7 L1764-7a	6	F
I	0	0	0	1	0	0	8 L1764-7b	6	F
							9 L1764-8	15	I
S	0	0	0	0	1	0	10 L1764-9a	9	D/FL
							11 L1764-9b	9	D/FL
X	0	0	0	0	0	1	12 L1764-10a	16	X
							13 L1764-10b	16	X
							14 L1764-10c	16	X
							15 L1764-11	20	D/FL
							16 L1764-12a	14	D/FL
							17 L1764-12b	14	D/FL

Interprétation

```
# A tibble: 7 × 5
  term                estimate std.error statistic p.value
<chr>                <dbl>    <dbl>    <dbl>    <dbl>
1 (Intercept)         14.0      10.0      1.40    0.162
2 school_pntgD/FL      2.33     10.0      0.232   0.816
3 school_pntgF        10.2      10.0      1.02    0.309
4 school_pntgG         1.65     11.9      0.139   0.889
5 school_pntgI        10.3      10.0      1.02    0.306
6 school_pntgS        30.4      11.4      2.68    0.00744
7 school_pntgX         2.87     10.3      0.279   0.780
```

- **École autrichienne** (A) est le niveau de référence. En moyenne, les peintures de cette école mesurent 14 pouces de haut.
- **École néerlandaise/flamande** (D/FL) : En moyenne, les peintures de cette école sont 2.33 pouces plus hautes que celles de l'école autrichienne.
- **École française** (F) : En moyenne, les peintures de cette école sont 10.2 pouces plus hautes que celles de l'école autrichienne.
- **École allemande** (G) : En moyenne, les peintures de cette école sont 1.65 pouces plus hautes que celles de l'école autrichienne.
- **École italienne** (I) : En moyenne, les peintures de cette école sont 10.3 pouces plus hautes que celles de l'école autrichienne.
- **École espagnole** (S) : En moyenne, les peintures de cette école sont 30.4 pouces plus hautes que celles de l'école autrichienne.
- **École inconnue** (X) : En moyenne, les peintures de cette catégorie sont 2.87 pouces plus hautes que celles de l'école autrichienne.

R^2 et R^2 ajusté

Mesurer la qualité d'ajustement

- **Coefficient de détermination (R^2)**: Proportion de la variance totale de la variable dépendante expliquée par le modèle.
 - Varie entre 0 et 1
 - Plus R^2 est proche de 1, meilleur est l'ajustement du modèle aux données.

```
1 linear_reg() %>%
2   set_engine("lm") %>%
3   fit(Height_in ~ Width_in, data = pp) %>%
4   glance()

# A tibble: 1 × 12
#   r.squared adj.r.squared sigma statistic p.value    df logLik   AIC    BIC
#   <dbl>      <dbl> <dbl>    <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl>
1     0.683        0.683  8.30     6749.     0     1 -11083. 22173. 22191.

# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

R^2 ajusté

- **Coefficient de détermination ajusté (R^2_{adj}):** Version ajustée de R^2 qui prend en compte le nombre de variables explicatives dans le modèle.
 - Utile pour comparer des modèles avec différents nombres de variables explicatives.

```
1 linear_reg() %>%
2   set_engine("lm") %>%
3   fit(Height_in ~ Width_in + landsALL + school_pntg, data = pp) %>%
4   glance()

# A tibble: 1 × 12
#   r.squared adj.r.squared sigma statistic p.value    df logLik   AIC    BIC
#   <dbl>      <dbl> <dbl>      <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl>
1  0.716      0.715  7.87        986.     0     8 -10910. 21840. 21901.

# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

Références

Peng, R. and Matsui, E. (2016). *The Art of Data Science*. Lulu.com.